





Méthode Deep Learning

METRIC LEARNING



Apprendre une fonction $f(x)$ qui projette une image dans un espace vectoriel de dimension $d=128$, où la distance euclidienne correspond directement à la similarité sémantique des visages.

RÉSEAU SIAMOIS



- Du fait qu'on fait des comparaisons, on utilise plusieurs réseaux en même temps (voir triplet loss).
- Même réseau de neurones dont les poids sont partagés.
- Le partage des poids garantit que deux images similaires projetées par la même fonction se retrouveront proches dans l'espace latent.

Triplet Loss




- L'algorithme prend un triplet d'images : une Ancre , une image Positive de la même personne , et une image Négative d'une autre personne .
- La fonction de coût vise à minimiser la distance entre l'Ancre et le Positif, tout en maximisant la distance entre l'Ancre et le Négatif, avec une marge imposée alpha

Hard Mining et fonction de cout


$$\mathcal{L}_{\text{BH}}(\theta; X) = \sum_{i=1}^P \sum_{a=1}^K \left[m + \overbrace{\max_{p=1 \dots K} D(f_{\theta}(x_a^i), f_{\theta}(x_p^i))}^{\text{hardest positive}} - \underbrace{\min_{\substack{j=1 \dots P \\ n=1 \dots K \\ j \neq i}} D(f_{\theta}(x_a^i), f_{\theta}(x_n^j))}_{\text{hardest negative}} \right]_+, \quad (5)$$

- Le Hard mining consiste a utiliser une approximation de notre fonction pour sélectionner les exemples les plus difficiles.
- Cela permet de rendre le réseaux résistant aux personnes qui se ressemblent.

Transfert learning



- Entraîner un CNN profond depuis zéro sur des millions de visages nécessite une puissance de calcul massive.
- Nous avons utilisé une partie d'un réseau pré-entraîné pour réaliser notre modèle.





- Geler les couches convolutives initiales, car elles savent déjà extraire des caractéristiques universelles (contours, textures, gradients).
- Remplacer la tête de classification originale par une nouvelle couche dense (Fully Connected) pour réduire la dimensionnalité à un vecteur d'embedding de taille 128.
- Fine-Tuning en n'entraînant que cette dernière couche via la Triplet Loss sur le dataset LFW (Labeled Faces in the Wild).

Distance : 2.4334

Seuil : 2.5 -> Verdict : même personne



Image 1







Distance : 3.0577


Seuil : 2.5 -> Verdict : personnes différentes

Image 1





Accuracy en fonction du taux de Fausse Alerte (FAR)



Applications

Webcam

reconnaissance
de visage
automatique